第六课 文字搜索和RAG

在之前我们做了一个模仿李白语气的聊天的机器人。仅仅通过把系统的提示词改为

```
你扮演唐朝著名诗人李白，请用李白的口吻和用户进行对话。
```

就可以初步实现这样的功能。然而，李白留下了千首左右的诗作。模型并不一定完整记忆了李白所有的诗词。这里我们希望使用一个“外挂数据库”的方法，来加强李白的记忆。形成一个类似

```
你扮演唐朝著名诗人李白

参考李白的诗词：
{随用户聊天变化的过往的李白的诗词}

请模仿李白的口吻和经历与我进行对话
```

的系统。当然，在课程中我们只模仿李白这样一个经典的历史人物，同学们可以自行把李白替换为自己喜欢的人物。这个时候，尤其当模型对要扮演的目标人物不了解时，这种外挂记忆库的方法就变得尤其重要了。这种使用搜索增强语言模型的生成能力的技术名称是RAG(Retrieval Augmented Generation)，是一种2023年前后随着语言模型兴起，才开始流行的技术。

载入外挂数据库

在data/李白.csv 我们存储了很多李白的诗。

	A	B
1	Title	Content
2	宿鲗湖	鸡鸣发黄山，暝投鲗湖宿。白
3	送别得书字	水色南天远，舟行若在虚。迁人
4	荅湖州迦叶司马问	青莲居士谪仙人，酒肆藏名三一
5	长门怨二首 一	天回北斗挂西楼，金屋无人萤火
6	送纪秀才游越	海水不满眼，观涛难称心。即矩
7	菩萨蛮	举头忽见衡阳雁，千声万字情何
8	夏日山中	懒摇白羽扇，裸体青林中，脱巾

我们让GPT帮我们载入对应的数据，

```
data/李白.csv 存储了很多李白的诗

对应的格式如下
```
Title,Content
襄阳曲四首 三,岘山临汉江，水绿沙如雪。上有堕泪碑，青苔久磨灭。
独坐敬亭山,合沓牵数峰，奔地镇平楚。中间最高顶，髣髴接天语。
```

帮我实现一段Python程序读取这个文件，以

{Title}::{Content}的形式合并标题和诗歌内容为一个字符串

把这些数据读取为一个list
```

GPT形成了下面的代码。

```python
import csv

# 初始化一个空列表来存储合并后的数据
merged_poems = []

# 读取CSV文件
with open('data/李白.csv', 'r', encoding='utf-8') as csvfile:
    reader = csv.DictReader(csvfile)
    for row in reader:
        # 合并标题和内容
        merged_str = f"{row['Title']}::{row['Content']}"
        # 将合并后的字符串添加到列表中
        merged_poems.append(merged_str)
```

这个merged_poems是一个Python中的列表

```python
# 显示列表的前几个元素以验证
merged_poems[:5]
```

结果

['宿鰕湖::鸡鸣发黄山，暝投鰕湖宿。白雨暎寒山，森森似银竹。提携采铅客，结荷水边沐。半夜四天开，星河烂人目。明晨大楼去，冈陇多屈伏。当与持斧翁，前溪伐云木。', '送别得书字::水色南天远，舟行若在虚。迁人发佳兴，吾子访闲居。日落看归鸟，潭澄羡跃鱼。圣朝思贾谊，应降紫泥书。', '荅湖州迦叶司马问白是何人::青莲居士谪仙人，酒肆藏名三十春。湖州司马何须问，金粟如来是后身。', '长门怨二首 一::天回北斗挂西楼，金屋无人萤火流。月光欲到长门殿，别作深宫一段愁。', '送纪秀才游越::海水不满眼，观涛难称心。即知蓬莱石，却是巨鳌簪。送尔游华顶，令余发鬲吟。仙人居射的，道士住山阴。禹穴寻溪入，云门隔岭深。绿萝秋月夜，相忆在鸣琴。']

Python中的列表

在这段代码中我们使用了Python中的线性存储结构List。显然，李白的诗歌是很多的，我们不可能用poem_0, poem_1这样的方式来命名和调用所有的古诗。这个时候我们希望有一种变量，可以以poems[0], poems[1]，甚至poems[i]的方式来访问每一首故事，这个poems，就是Python中的List。

```
我正在学习Python中的List。请用循环的方式生成一个粒子一维布朗运动的数据

以list of float的形式输出，并进行可视化
```

GPT的输出

```python
import matplotlib.pyplot as plt
import random

# 参数设置
n_steps = 1000  # 时间步数
delta_t = 1.0   # 每步时间间隔
delta_x = 1.0   # 每步位移大小

# 生成一维布朗运动数据
brownian_motion = [0]  # 初始位置
for _ in range(n_steps):
    step = brownian_motion[-1] + random.choice([-delta_x, delta_x])
    brownian_motion.append(step)
```

结果

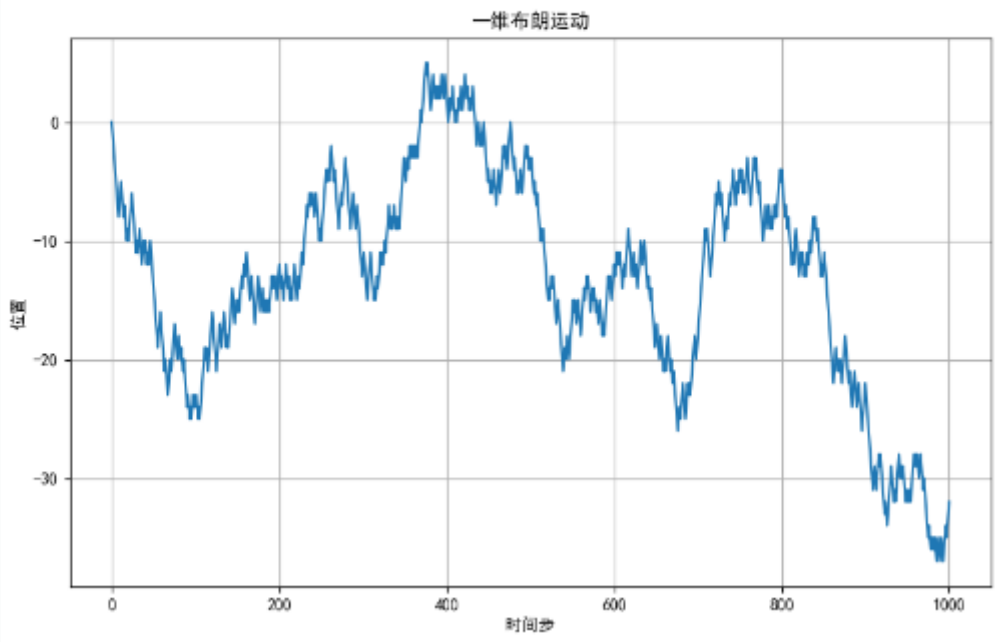

在这段代码中，最终得到了一个字符串List merged_poems，我们可以向GPT询问关于列表的知识

```
什么是Python中的List，请给我举出基本的例子
```

List的基本知识

在Python中，List（列表）是一种有序的集合，可以包含不同类型的元素，如数字、字符串、甚至是其他列表。列表是可变的，这意味着你可以修改、添加或删除列表中的元素。

以下是一些基本的List例子：

1. 创建一个包含不同类型元素的列表：

```
my_list = [1, 'hello', 3.14, [2, 'world']]
```

2. 访问列表中的元素（索引从0开始）：

```
print(my_list[0])  # 输出: 1
print(my_list[1])  # 输出: 'hello'
print(my_list[-2])  # 输出倒数第二个元素 '3.14'
```

3. 修改列表中的元素：

```
my_list[2] = 2.71
print(my_list)  # 输出：[1, 'hello', 2.71, [2, 'world']]
```

4. 向列表中添加元素：

```
my_list.append('new_element')
print(my_list)  # 输出：[1, 'hello', 2.71, [2, 'world'], 'new_element']
```

5. 删除列表中的元素：

```
del my_list[3]
print(my_list)  # 输出：[1, 'hello', 2.71, 'new_element']
```

6. 列表切片：

```
sub_list = my_list[1:3]  # 包含索引1和2的元素，不包括索引3
print(sub_list)  # 输出：['hello', 2.71]
```

这些例子展示了Python列表的基本用法。列表是Python编程中非常强大和灵活的数据结构。

和List有关的prompt组织

如果同学们的代码中，需要存储一定规模的数据。并且一批数据具有相同的特性，那么很大概率会用到List这种数据结构。在prompt中，很多时候要明确说明某个变量是一个List。

下面是我们在编程中，可能会围绕list出现的一些prompt的语句

```
{变量名}是一个list of {数据类型}

输出为一个  list of {数据类型}

{变量名}是一个list，其中每个元素。。。
```

这里Python中的List和有一些编程语言中的“数组”是有一定的差异的。因为Python是动态类型绑定的所以Python的List的元素可以是“各异”的，在前面的例子中可以看到，这和C++为主的静态类型语言有所不同。不过，当你和GPT描述的时候，使用“数组”这个词，仍然可以被GPT正确理解。

检查一个字在李白哪些诗歌中出现

在最终当然我们一开始可以先做一些有趣的练习，我们可以看看李白的诗歌中，哪些字出现的概率是最大的。

```
merged_poems是一个list of string，存储着李白的诗歌

我想看看李白的诗歌中出现概率最高的三十个字是什么，请用python为我实现

去除掉标点符号，将结果用条形图可视化
```

GPT生成的代码为

```python
import re
from collections import Counter
import matplotlib.pyplot as plt

all_poems = "".join(merged_poems) # 将所有诗歌合并成一个字符串，并去除标点符号
all_poems = re.sub(r'[，。：]', '', all_poems)

word_counts = Counter(all_poems) # 计算每个字的出现频率

top_30_words = word_counts.most_common(30) # 获取出现频率最高的30个字

#... 后续为plt绘图代码
```

这里我们可以看到有一些比如“天”，“云”，“风”的意象在诗中都是高频出现的。

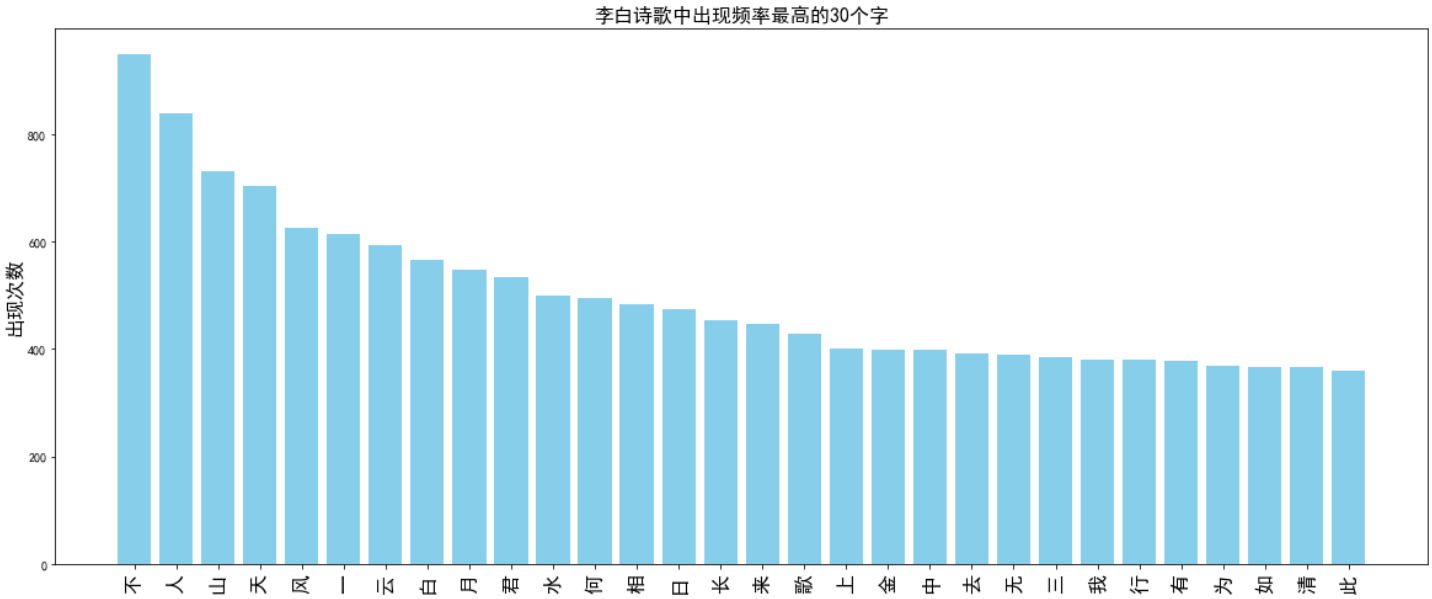

这里我们要注意的是，在需求的prompt中，我们明确地指出了"merged_poems是一个list of string"，这样我们明确地向GPT说明了我们需要处理地变量的类型。方便GPT更准确地生成程序。

现在，我们要开始搭建我们的搜索系统，对于任意的一个字，我们想知道这个字在哪几首古诗里面出现了。显然，将这部分功能实现为一个函数是较为合理的。想一想，对应函数的输入和输出都是什么？

```
我希望实现一个Python函数 search_character( character, merged_poems )

其中character是有待搜索的汉字， merged_poems是list of string存储了很多诗歌

我希望搜索character在哪几首诗歌中出现了。
```

GPT对应的代码是

```python
def search_character(character, merged_poems):
    # 存储包含特定字符的诗歌列表
    poems_with_char = []

    # 遍历每首诗歌
    for poem in merged_poems:
        # 分割标题和内容
        title, content = poem.split('::')
        # 检查字符是否在诗歌内容中出现
        if character in content:
            poems_with_char.append(title)

    return poems_with_char
```

```
14
15 # 测试函数
16 search_character('月', merged_poems)
```

检查一句话中字和那首诗的重合度最高

当然，对于我们的应用来说

```
1 我希望实现一个Python函数 search_sentence( sentence, merged_poems )
2
3 用来查询sentence中的字和那几首古诗中的字的重合度最高
4
5 其中sentence是有待搜索的句子， merged_poems是list of string存储了很多诗歌
6
7 对于sentence中的每个字 搜索和计数merged_poems中对应字是否出现来累计重合度
8
9 把重合度最高的前三首诗歌进行返回
```

GPT的输出如下

```
1 def search_sentence(sentence, merged_poems):
2     most_similar_poems = [] # 存储与查询句子重合度最高的诗歌列表
3
4     for poem in merged_poems: # 遍历每首诗歌
5         # 计算查询句子与诗歌内容的重合度
6         similarity = sum(1 for word in sentence if word in poem)
7         # 添加到列表中
8         most_similar_poems.append((poem, similarity))
9
10    # 对列表进行排序，按重合度降序排列
11    most_similar_poems.sort(key=lambda x: x[1], reverse=True)
12
13    # 返回重合度最高的前三个诗歌
14    return [poem for poem, _ in most_similar_poems[:3]]
15
16 # 测试函数
17 search_sentence('清风明月', merged_poems)
```

并且GPT还自己找了个“清风明月”的测试样例，对应的输出是

```
1 ['上清宝鼎诗二首 二::...既死明月魄，...。', '宣城送刘副使入秦::...。凄清横吹曲，慷慨扶风
```

```
词。...月明关山苦，水剧陇头悲。...’，‘扶风豪士歌::洛阳三月飞胡沙，...，来醉扶风豪士家。...明日报恩知是谁。...，清水白石何离离...’]
```

组装system prompt

```
我已经实现了search_sentence(sentence, merged_poems ) ，
会根据 sentence，搜索至多三句最接近sentence的李白的诗词，以list of string的形式进行输出

我希望实现一个sentence2prompt( sentence, merged_poems )函数，

根据输入的sentence，返回一个字符串

"""
你扮演唐朝著名诗人李白

参考李白的诗词:
{诗歌一}
{诗歌二}
{诗歌三}

请模仿李白的口吻和经历与我进行对话
"""
```

GPT的代码

```python
def sentence2prompt(sentence, merged_poems):
    # 使用search_sentence函数找到最接近的诗词
    similar_poems = search_sentence(sentence, merged_poems)

    # 初始化prompt字符串
    prompt = "你扮演唐朝著名诗人李白\n\n参考李白的诗词:\n"

    # 将找到的诗词添加到prompt中
    for poem in similar_poems:
        prompt += f"{poem}\n"

    # 添加最后的对话指示
```

```
    prompt += "\n请模仿李白的口吻和经历与我进行对话"

    return prompt

print(sentence2prompt('月亮下的独酌', merged_poems))
```

组合所有的代码

```
我已经实现了

{lesson4/libai_gradio.py的代码}

的代码

我希望把其中的system_prompt，替换为

sentence2prompt(sentence, merged_poems)函数的结果

其中sentence2prompt的代码为

{sentence2prompt的代码}

search_sentence的代码为

{search_sentence的代码}

merged_poems的获取方式为

{merged_poems的读取方法}

请为我组合出修改后的代码
```

当然，有一定代码能力的同学也可以自己将各个部分的代码粘贴在一起。对应的代码我们放在了lesson6/libai_RAG_v0.py中，同学们可以自行进行阅读。

对比RAG的效果

为了方便对比使用和不使用RAG的效果差异，这里老师额外实现了 lesson6/libai_RAG_v1.py。这里同学们可以将两个版本的python文件都上传给GPT，并且询问GPT

```
对比v0和v1的代码，看看v1比v0增加了哪些功能。
```

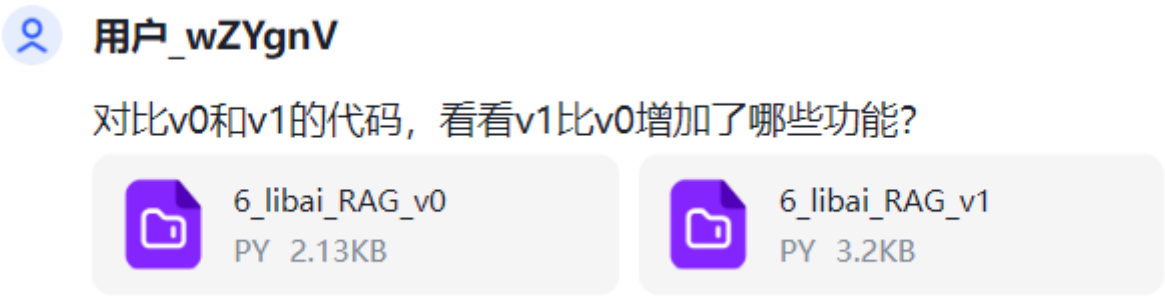

这是GPT的回答:

以下是v1.py相对于v0.py所做的更改和增加的功能：

1. ...
2. ...
3. 更改了 `question2response` 函数的签名，增加了两个新参数： `chat_history` 和 `use_rag_radio` 。此函数现在根据是否启用RAG功能有条件地设置 `system_prompt` 。
4. 在 `question2response` 函数内部，新增了条件逻辑，构建了一个消息列表发送给ZhipuAI API。如果可用，这个列表包括了聊天历史，聊天历史被切到最后的两条消息。
5. 更新了Gradio界面：
   - ...
   - 添加了一个新的 `Radio` 组件 `use_rag_radio` ，提供选择使用或不使用RAG的选项。
   - 添加了一个新的 `TextArea` 组件 `rag_search_result` ，用于显示RAG搜索结果。
6. ...
7. ...
8. ...

实际总结下来就是增加了是否使用我们这节课额外实现的RAG系统，以及额外显示了RAG的结果。

这里我们可以用几个句子

```
你的族弟李沈，你还记得吗?
宇文太守是谁?
```

来测试增加了诗词RAG后的效果。

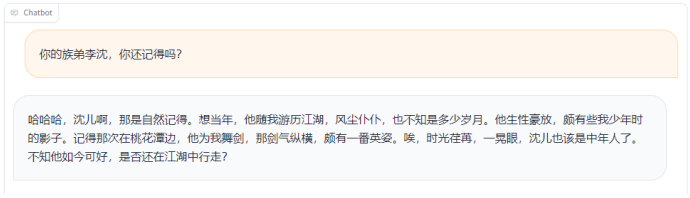

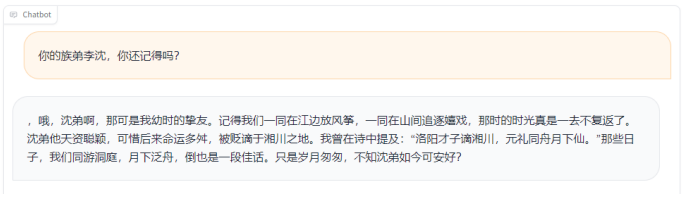

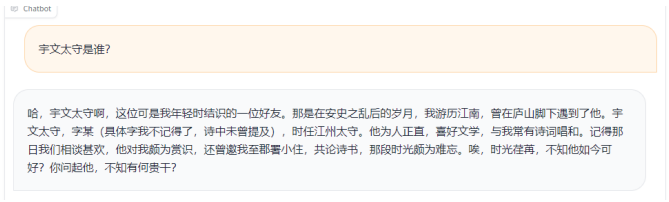

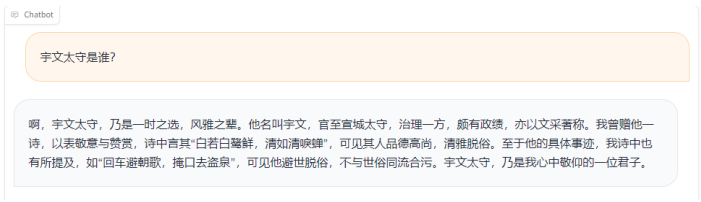

右侧是带了RAG的效果，可以看到，当我们带上对应的RAG的时候，对于宇文太守，以及李白族弟的信息回复，会显得更准确。

总结

这里我们实践了一个简易版本的“RAG检索增强”系统。在李白角色扮演这样一个任务中，对语言模型进行了增强。当然，这里如果把李白换成一个模型更不熟悉的人物，比如某个电视剧、小说或者动漫中的人物，对比的效果将会更显著。不过受到版权的限制，我们这里教学的例子还是以李白为例，同学们可以自行替换喜欢的角色。

课后练习

连续两个字构成的词语

对于李白的诗歌，考虑连续两个字构成的“词”，统计这样词的出现频率。找到出现频率最高的30个词。

英雄数据的读取和可视化

将data/英雄分类.xlsx中的数据进行读取，读取英雄某个维度的属性，并转化为list of int，并进行直方图的可视化。

将英雄某两个维度的数据进行散点图的可视化。查看list数据结构在其中的作用。

小车轨迹的记录

在Pygame吃豆子的课程中，有一个随着鼠标点击移动的小车的例子。为小车增加历史轨迹的显示。分析GPT输出的代码中是否有线性存储结构的存在。如果有是否使用了List，还是其他形式的数据结构？

将李白替换为其他人物

访问https://github.com/LC1332/Chat-Haruhi-Suzumiya项目的characters文件夹，会发现大量的其他人物。对应的语料放在了每个人物对应的文件夹。尝试将李白聊天的程序，替换为其他人物的程

序。你可能需要通过两个步骤来实现这个修改

- 将csv载入的方式，替换为扫描text文件夹中的语料，载入所有的txt文件为list of string
- 修改李白的system prompt为其他特定人物的prompt